Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)»

(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Отчёт по РК2

«Технологии машинного обучения»

Вариант 1

Выполнил:

студент группы ИУ5-63Б

Абрамов В.Г.

Преподаватель:

Гапанюк Ю. Е.

2023 г.

Задание: Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Метод №1: Дерево решений

Метод №2: Случайный лес

Датасет: https://www.kaggle.com/mohansacharya/graduate-admissions (файл Admission_Predict_Ver1.1.csv)

Решение:

Импортируем необходимые модули и загружаем данные из файла 'Admission_Predict_Ver1.1.csv' в объект `df`. Выводим первые строки данных с помощью `head()` и получаем информацию о данных с помощью `info()`. Удаляем столбец 'Serial No.' и подсчитываем количество пропущенных значений с помощью `isnull().sum()`.

In [1]:
```
import pandas as pd
import warnings
warnings.filterwarnings("ignore")
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

from sklearn.metrics import mean_absolute_error, mean_squared_error, median_absolute_error, r2_score
from sklearn.preprocessing import MinMaxScaler
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.impute import SimpleImputer, MissingIndicator
from sklearn.preprocessing import LabelEncoder, OneHotEncoder, MinMaxScaler
from sklearn.model_selection import StratifiedKFold
from sklearn.model_selection import cross_val_score
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, accuracy_score
from sklearn.svm import SVC, NuSVC, LinearSVC
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor
from sklearn.model_selection import GridSearchCV
from sklearn import tree
from IPython.core.display import HTML
from sklearn.tree import export_text
from operator import itemgetter
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_predict
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import GradientBoostingClassifier
```

In [2]:
```
df = pd.read_csv('Admission_Predict_Ver1.1.csv')
```

In [3]:
```
df.head()
```

Out[3]:

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit
0	1	337	118	4	4.5	4.5	9.65	1	0.92
1	2	324	107	4	4.0	4.5	8.87	1	0.76
2	3	316	104	3	3.0	3.5	8.00	1	0.72
3	4	322	110	3	3.5	2.5	8.67	1	0.80
4	5	314	103	2	2.0	3.0	8.21	0	0.65

In [4]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 9 columns):
 #   Column             Non-Null Count  Dtype  
---  ------             --------------  -----  
 0   Serial No.         500 non-null    int64  
 1   GRE Score          500 non-null    int64  
 2   TOEFL Score        500 non-null    int64  
 3   University Rating  500 non-null    int64  
 4   SOP                500 non-null    float64
 5   LOR                500 non-null    float64
 6   CGPA               500 non-null    float64
 7   Research           500 non-null    int64  
 8   Chance of Admit    500 non-null    float64
dtypes: float64(4), int64(5)
memory usage: 35.3 KB
```

In [5]:
```
df = df.drop(['Serial No.'], axis=1)
df.isnull().sum()
```

Out[5]:
```
GRE Score          0
TOEFL Score        0
University Rating  0
SOP                0
LOR                0
CGPA               0
Research           0
Chance of Admit    0
dtype: int64
```

Создаём матрицу корреляции и визуализируем её с помощью тепловой карты, чтобы оценить связи между признаками в данных.

```
In [6]: corr = df.corr()
        sns.heatmap(corr, linewidths=.5, annot=True, fmt=".2f")
        plt.show()
```

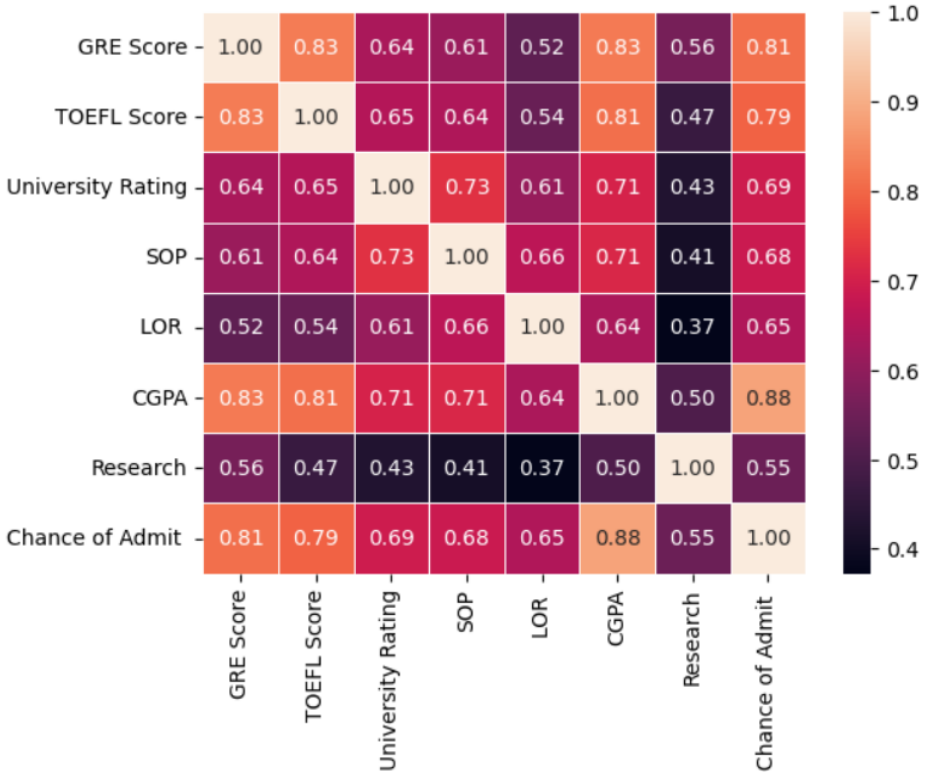

Наиболее сильная корреляция с целевым признаком "Chance of Admit" наблюдается у признаков "CGPA", "GRE Score" и "TOEFL Score". При построении модели машинного обучения эти признаки будут наиболее информативными и важными для прогнозирования результата. Следует отметить наличие корреляции между признаками "SOP" и "University Rating". Это может указывать на взаимосвязь между качеством заявки на поступление (SOP) и рейтингом университета, где студент подает заявку. Можно построить модель машинного обучения, используя признаки "CGPA", "GRE Score", "TOEFL Score", "LOR" и "Research". При этом особенно важными являются первые три признака, так как они сильно коррелируют с результатом.

Далее выполняем удаление столбца 'Chance of Admit', кодируем столбец 'Chance of Admit' из строковых значений в числовые и разбиваем данные на обучающую и тестовую выборки в соотношении 80/20.

```
In [7]: X = df.drop(['Chance of Admit '], axis=1) #Наименования признаков
        y = df['Chance of Admit '] # Значения признаков

In [8]: # кодируем категориальные данные из строк в числа
        le = LabelEncoder()
        y = le.fit_transform(y)

In [9]: X_train, X_test, y_train, y_test = train_test_split(X,y,test_size = 0.20, shuffle=False)

In [10]: # Размер обучающей выборки
         X_train.shape, y_train.shape
Out[10]: ((400, 7), (400,))

In [11]: # Размер тестовой выборки
         X_test.shape, y_test.shape
Out[11]: ((100, 7), (100,))
```

Затем создаем регрессор DecisionTreeRegressor с максимальной глубиной 5 и обучаем его на обучающих данных. Затем мы строим **дерево решений** для визуализации полученной модели. Далее, мы создаем классификатор DecisionTreeClassifier с указанным случайным состоянием и обучаем его на обучающих данных. Также определена функция test_model() для оценки модели с использованием различных метрик. В конце вызываем функцию test_model() для оценки модели dt_none на тестовых данных.

```
In [12]: dt_none = DecisionTreeRegressor(max_depth=5)
         dt_none.fit(X_train, y_train)
Out[12]: DecisionTreeRegressor(max_depth=5)

In [13]: tree.plot_tree(dt_none);
```

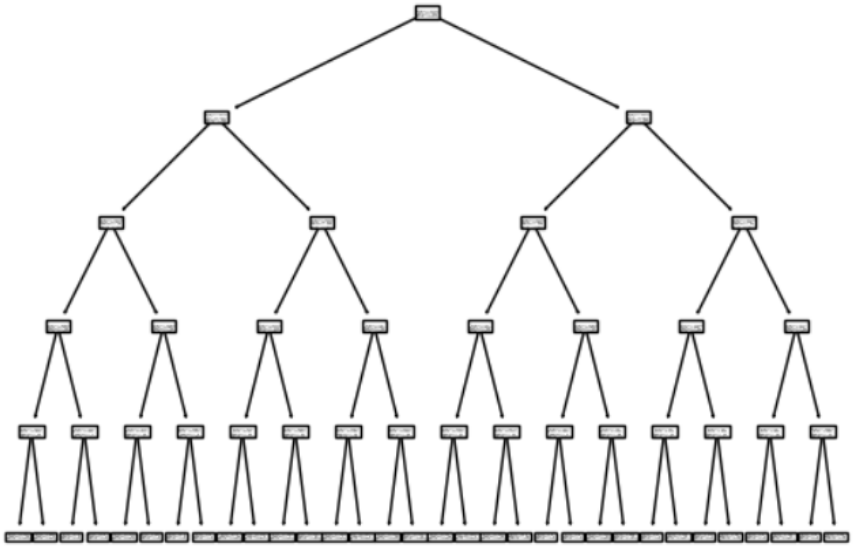

In [14]:
```
clf = DecisionTreeClassifier(random_state=1)
clf.fit(X_train, y_train)
```

Out[14]:
```
DecisionTreeClassifier(random_state=1)
```

In [15]:
```
def test_model(model):
    print("mean_absolute_error:",
        mean_absolute_error(y_test, model.predict(X_test)))
    print("median_absolute_error:",
        median_absolute_error(y_test, model.predict(X_test)))
    print("r2_score:",
        r2_score(y_test, model.predict(X_test)))
```

In [16]:
```
test_model(dt_none)
```

```
mean_absolute_error: 4.4544738590581145
median_absolute_error: 3.31111111111111
r2_score: 0.7901077601317965
```

Определим функцию `draw_feature_importances`, которая выводит график важности признаков на основе модели дерева решений (`clf`) и набора данных признаков (`X_train`). График отображает столбцы с названиями признаков и их важностью, а также выводит значения важности над соответствующими столбцами.

In [17]:
```
def draw_feature_importances(tree_model, X_dataset, figsize=(18, 5)):
    """
    Вывод важности признаков в виде графика
    """
    # Сортировка значений важности признаков по убыванию
    list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances_))
    sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse=True)

    # Названия признаков
    labels = [x for x, _ in sorted_list]
    # Важности признаков
    data = [x for _, x in sorted_list]

    # Вывод графика
    fig, ax = plt.subplots(figsize=figsize)
    ind = np.arange(len(labels))
    plt.bar(ind, data)
    plt.xticks(ind, labels, rotation='vertical')

    # Вывод значений
    for a, b in zip(ind, data):
        plt.text(a - 0.05, b + 0.01, str(round(b, 3)))

    plt.show()

    return labels, data
```

In [18]:
```
dt_fl, dt_fd = draw_feature_importances(clf, X_train)
```

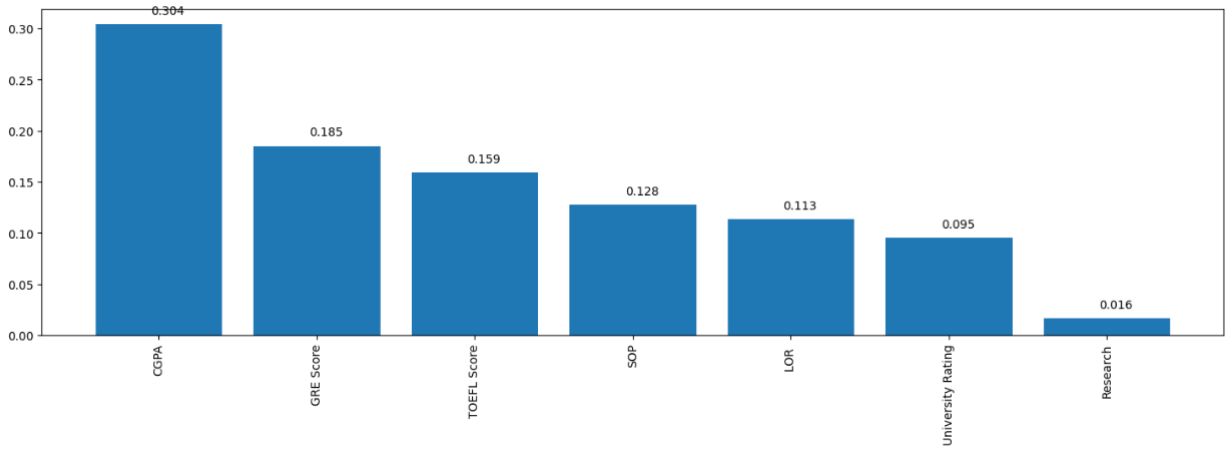

Далее выполняем поиск наилучших параметров для модели `DecisionTreeClassifier` с помощью кросс-валидации и оцениваем ее точность на тестовых данных, а также сравниваем ее с другими моделями.

In [19]:
```
tree = DecisionTreeClassifier()

param_grid = {'max_depth': [2, 4, 6, 8, 10],
              'min_samples_split': [2, 4, 6, 8, 10],
              'min_samples_leaf': [1, 2, 3, 4, 5]}
grid_search = GridSearchCV(tree, param_grid=param_grid, cv=5)
grid_search.fit(X_train, y_train)
accuracy_tree = grid_search.best_estimator_.score(X_test,y_test)

print("Наилучшие   параметры: {} ", grid_search.best_params_)
print("Оценка точности на кросс-валидации: {:.2f}".format(grid_search.best_score_))
print(accuracy_tree)
```

```
Наилучшие   параметры: {}  {'max_depth': 4, 'min_samples_leaf': 3, 'min_samples_split': 10}
Оценка точности на кросс-валидации: 0.10
0.14
```

In [20]:
```
models = [['DecisionTree :',DecisionTreeRegressor()]]
```

In [21]:
```
print('Вывод 1')
for name,model in models:
    model = model
    model.fit(X_train, y_train)
    predictions = model.predict(X_test)
    print(name, (np.sqrt(mean_squared_error(y_test, predictions))))
```

```
Вывод 1
DecisionTree : 9.311820445004296
```

In [22]:
```
models = [['DecisionTree:', DecisionTreeRegressor(max_depth=6)],
          ['Линейная регрессия:', LinearRegression(normalize=True)],
          ['SVC:', SVC(C=1, kernel='linear')]]
```

In [23]:
```
print('Вывод 2')
for name,model in models:
    model = model
    model.fit(X_train, y_train)
    predictions = model.predict(X_test)
    print(name, (np.sqrt(mean_squared_error(y_test, predictions))))
```

```
Вывод 2
DecisionTree: 7.257068113982736
Линейная регрессия: 4.233037381515526
SVC: 6.495382975621991
```

После создаем модель **случайного леса** (`RandomForestClassifier`), обучаем ее на тренировочных данных, оцениваем ее точность на тестовых данных, а затем выполняем поиск наилучших параметров для модели с помощью кросс-валидации и оцениваем ее точность на тестовых данных с использованием найденных параметров.

In [24]:
```
# Создаем модель случайного леса с 100 деревьями
rf_model = RandomForestClassifier(n_estimators=100)
# Обучаем модель на тренировочных данных
rf_model.fit(X_train, y_train)
# Оцениваем качество модели на тестовых данных
accuracy = rf_model.score(X_test, y_test)
print('Accuracy: {:.2f}%'.format(accuracy*100))
```

```
Accuracy: 8.00%
```

In [25]:
```
model = RandomForestClassifier()
param_grid = {
    'n_estimators': [200, 700],
    'max_features': ['auto', 'sqrt', 'log2']
}

grid_search = GridSearchCV(model, param_grid=param_grid, cv=5)
grid_search.fit(X_train, y_train)
accuracy_RandomForestClassifier = grid_search.best_estimator_.score(X_test,y_test)

print("Наилучшие  параметры: {} ", grid_search.best_params_)
print("Оценка точности на кросс-валидации: {:.2f}".format(grid_search.best_score_))
print(accuracy_tree)
```

```
Наилучшие  параметры: {}  {'max_features': 'sqrt', 'n_estimators': 700}
Оценка точности на кросс-валидации: 0.14
0.14
```